

引文格式: 赵 刚, 杨必胜. 基于Gradient Boosting的车载LiDAR点云分类[J]. 地理信息世界, 2016, 23(3): 47–52.

基于Gradient Boosting的车载LiDAR点云分类

赵 刚, 杨必胜

(武汉大学 测绘遥感信息工程国家重点实验室, 湖北 武汉 430079)

基金项目:

国家自然科学基金项目
(41371431) 资助

作者简介:

赵 刚(1992–), 男, 安徽安庆人, 地图制图学与地理信息工程专业硕士研究生, 主要研究方向为激光雷达点云分类与目标识别。

E-mail:

stylezg@whu.edu.cn

通讯作者:

杨必胜(1975–), 男, 安徽霍邱人, 教授, 博士, 博士生导师, 主要从事激光雷达数据特征提取与三维重建, 多源空间数据多尺度几何建模, 智能位置服务等研究工作。

E-mail:

bshyang@whu.edu.cn

收稿日期: 2016-02-25

【摘要】 车载LiDAR点云中包含地面、建筑物、行道树、路灯等丰富地物类别, 自动对这些不同类别点云进行分类, 对点云中目标的识别、提取及重建都具有重要意义。本文提出了一种基于Gradient Boosting的自动分类方法。该方法首先对车载激光点云进行数据预处理, 然后计算点云的协方差矩阵、密度比、高程相关特征、局部平面特征、投影特征等, 再计算点云特征直方图与垂直分布直方图, 采用K-means方法对这两者分别进行聚类, 并将其聚类类别值也作为特征, 从而构建出20维的点云特征向量, 应用Gradient Boosting分类方法进行自动分类。为了验证本文方法的有效性, 从某城镇场景的车载激光点云数据中选取部分代表区域共144W点作为训练数据集, 然后选取另一较大区域的点云共312W点作为测试数据集。使用训练好的分类器对测试数据集进行分类, 分类结果总体准确率达到了93.38%, 耗时631s, 说明此分类方法具有较高的分类准确率, 同时也具备较高的效率。

【关键词】 点云分类; 特征向量; 特征直方图; 聚类; Gradient Boosting

【中图分类号】 P208

【文献标识码】 A

【文章编号】 1672-1586(2016)03-0047-06

Mobile LiDAR Point Cloud Classification Based on Gradient Boosting

ZHAO Gang, YANG Bisheng

(The State Key Laboratory of Information Engineering in Surveying, Mapping and Remote Sensing,
Wuhan University, Wuhan 430079, China)

Abstract: Mobile LiDAR point cloud contains abundant objects such as ground, building, tree, streetlight, etc. Automatic classification of these different points is of great importance to the object recognition, extraction and reconstruction from point cloud. The paper proposed an automatic classification method based on Gradient Boosting. With the method, firstly the point cloud is pre-processed, then calculated co-variance matrix, density ratio, features derived from elevation and local plane, horizontal projection area and vertical projection area. After these calculations, the point cloud feature histogram and vertical distribution histogram are calculated and clustered respectively. Coupled with the two cluster labels, a point feature vector with a dimension of 20 could be built. Then, point cloud could be classified automatically through applying a Gradient Boosting classifier. To prove the effectiveness of the method, a train dataset (144W points) and a test dataset (312W points) are selected from a mobile laser scanning point cloud dataset. Using the trained classifier to classify the test dataset, an overall accuracy is reached as high as 93.38% with consuming 631s. The method has a high classification accuracy as well as high efficiency when it is applied in a mobile laser scanning point cloud classification task.

Key words: point cloud classification; feature vector; feature histogram; cluster; Gradient Boosting

0 引 言

车载LiDAR即车载三维激光扫描仪, 是目前城市区域获取三维数据最有效的工具之一。其获取的数据密度高、精度好, 并且能够快速获取大面积区域的数据, 因此, 在数字城市、公路测量及检测、无人驾驶等领域都得到了广泛应用。车载激光点云的分类是车载激光数据处理流程中的一个重要环节, 对于目标的识别、提取与重建具有十分重要的作用。与机载LiDAR相比, 车载

LiDAR数据密度更大、场景更加复杂、遮挡情况更加严重, 导致其分类更加困难。目前, 主要有3类针对车载激光点云的分类方法: ①基于预定义规则对点云进行分类^[1-3]; ②自动标注与人工干预相结合的方法^[4]; ③使用机器学习的方法进行自动分类^[5-6]。由于车载激光点云数据细节丰富, 不同区域的同一类别点云空间分布及其特征可能存在较大差异, 如树木、建筑物等, 并且部分区域如遮挡处的场景更加复杂, 因此, 基于预定义规则的方法往往难以适应不同数据。而半自动的方法尽管

由于人工干预能够取得较好的分类结果,但效率较低。本文结合机器学习方法,根据点云的分布及邻域关系计算特征向量,进行监督分类,从而提高分类的稳健性和效率。

1 车载扫描点云特征向量的构建

车载激光点云数据中往往存在飞点,以及遮挡或建筑物玻璃等导致的大量无效点,因此需要预先剔除,避免影响分类效果。对于场景中非静止的行人、车辆等造成的无效点,也予以剔除。本文采用的剔除方法为统计离群点移除:首先,估计点云的平均点间距 d ,然后对每一个点,计算其到附近 K 个点的平均点间距,如果超出阈值 λd ($\lambda \geq 1$),便认为是离群点。对于不同高程的点,可设置不同的系数 λ ,避免电力线等被错误剔除。

由于激光点云数据是空间分布的离散三维点,为了能够进行分类,需要根据每个点的邻域空间分布计算其特征向量,用于后续的训练及分类。本文使用了面性、线性等协方差矩阵特征、高程相关特征、点法向特征、密度相关特征、投影特征,以及点云直方图与垂直分布等特征。

1) 协方差矩阵特征

通过计算某点邻域内所有点的协方差矩阵及其特征值 ($\lambda_1 > \lambda_2 > \lambda_3$),可以获得这一点的线性 (L_λ)、面性 (P_λ) (如图2(a)所示)及球性 (S_λ) 3个特征^[7]。

$$\begin{aligned} L_\lambda &= \frac{\lambda_1 - \lambda_2}{\lambda_1} \\ P_\lambda &= \frac{\lambda_2 - \lambda_3}{\lambda_1} \\ S_\lambda &= \frac{\lambda_3}{\lambda_1} \end{aligned}$$

这3个特征可以有效地表达点的局部几何特征,能够有效地区分地面建筑物立面等面目标、电线杆等杆状目标以及树冠等球状目标。

2) 高程相关特征

高程相关特征包括当前点到局部最低点距离 (Δ_z),以及邻域内Z值标准差 (σ_z)两个相关特征如图2(b)所示。对于建筑物高层立面及屋顶而言,其 Δ_z 值通常会远大于其他点,因此,可以有效地区分建筑立面

除底部外的大部分点以及屋顶点。而 σ_z 值则可以用于识别地面等水平面。

3) 局部平面特征

使用平面拟合某点与其邻域内所有点,可以计算出该点的法方向与垂直方向夹角 (D_n) 如图2(c)所示。对于地面,往往会得到较小的 D_n 值。由邻域内所有点的 D_n 值,可计算其标准差 σ_n 。 σ_n 反映了邻域内点的局部拟合平面与水平面的偏离程度差异,对于树冠等目标,会得到较大的值。此外,对于树冠、灌木等局部分布差异大的目标,当前点到其拟合平面的距离 (D_p) 通常会比较大,而对于建筑立面、地面、围墙等目标, D_p 值会很小。因此,此特征可以有效地区分树冠及地面围墙等。

4) 密度相关特征

邻域内的点云密度反映了点云的分布情况,如植被等可被穿透的目标的邻域点云密度通常大于建筑物,而将点云投影到 XOY 平面上后计算的邻域点云密度则可以反映建筑物、植被目标。计算密度比 (DR),如图2(d)所示^[8],密度比可以区分建筑物等高大的目标与地面,也可区分树木与低矮的灌木。

$$DR = \frac{N_{3D}}{N_{2D}} \times \frac{1}{r} \times \frac{3}{4}$$

式中, N_{3D} 是在3D邻域内计算的点数,而 N_{2D} 是在2D平面邻域内计算的点数。

5) 投影特征

通过将邻域点云投影到不同平面上,可以获取其侧面或剖面信息^[9]。首先,将邻域内的点云投影到 XOY 平面上,计算投影面积,如图2(e)所示。 P_n 表明了邻域内点云在水平方向上的分布情况,对于树冠、地面等,由于邻域内点云基本呈水平分布,因此,具有较大的值,而路灯、电线杆等目标的 D_n 值则较小。

竖直投影面可以每隔一定角度选择一个得到 (如 10°),然后将邻域内点云投影到所有竖直投影面上,计算投影面积并选择最小值作为其竖直投影面积 P_v 。建筑物立面、围墙等目标通常具有较小的 P_v 值,而植被、灌木等则具有较大的 P_v 值。

6) 点云特征直方图

前述特征如协方差矩阵特征等,都是由邻域估算

出该点的特征值, 难以反映其邻域的整体分布, 因此, 某些不同的目标点可能会计算出相同的特征值, 如房屋边缘与植被点等。为了减少这种误分类, 本文引入了点云特征直方图 (PFH) ^[10]。点云特征直方图是通过计算邻域内所有点对及其局部拟合平面法向量的关系得出。为了计算一对点对 (p_t, p_s) 的关系, 首先需要在其中一点上定义一个局部坐标系 (u, v, w) , 如图1所示。




图1 定义局部坐标系, 计算两点关系
Fig.1 Defining local coordinate system, calculating the relation between two points

使用此坐标系, 即可计算两个点的法向量 n_s, n_t 的关系:

$$\alpha = v \times n_t$$
$$\phi = u \cdot \frac{(p_t - p_s)}{d}$$
$$\theta = \arctan (w \times n_t, u \times n_t)$$

式中, d 是两点的欧式距离。在任意一点的邻域内对每一点计算出一组 (α, ϕ, θ) , 并且对这3个特征值分别划分为 b 个区间 (本文中 b 为11), 从而能够得到一个长度为 $3b$ 的直方图。对于不同的几何面, PFH均表现出不同的分布。因此, 可以提高识别具有相似邻域点分布的目标的准确率。

为了将点云特征直方图加入本文构建的点云特征向量, 需要先对所有训练样本点的特征直方图进行聚类。本文选择K-Means聚类方法, 将所有点的直方图聚为 aK ($a \geq 1$) 类, 其中, K 为分类的类别数, a 为系数。聚类完成后, 将聚类类别值 L_{fph} 作为特征值, 加入点云特征向量。

7) 垂直分布特征

与机载激光点云不同, 车载激光点云在垂直方向上具有多样的分布, 如建筑物立面、行道树、围墙等都具有不同的垂直分布, 这种分布在基于邻域的特征里难

以得到表达。因此, 本文提出了一种垂直分布特征直方图 (VP), 作为一种垂直方向上的环境上下文, 可减少邻域特征相似的不同目标的误分类。垂直分布特征直方图由某一点2D邻域内垂直方向上所有的点参与计算得出。首先在垂直方向每隔一定距离 c 从低到高划分为 s 个切片 (本文中 c 为1m, s 为15), 针对每一个切片, 计算出若干个3D邻域特征, 将所有特征组合构成一个垂直分布直方图。为了减少计算量, 可以使用已经计算出的前述局部邻域特征来计算切片内的特征均值和方差, 作为此切片特征。

为了将垂直分布特征直方图加入点云特征向量, 先对所有训练数据集的垂直分布特征直方图进行聚类。将聚类类别值 L_{vp} 作为特征值加入点云特征向量。此外, 根据划分的切片 (由2D邻域内最低点至最高点划分), 计算出非空的切片数 N_p , 如图2 (f) 所示, 并加入点云特征向量。

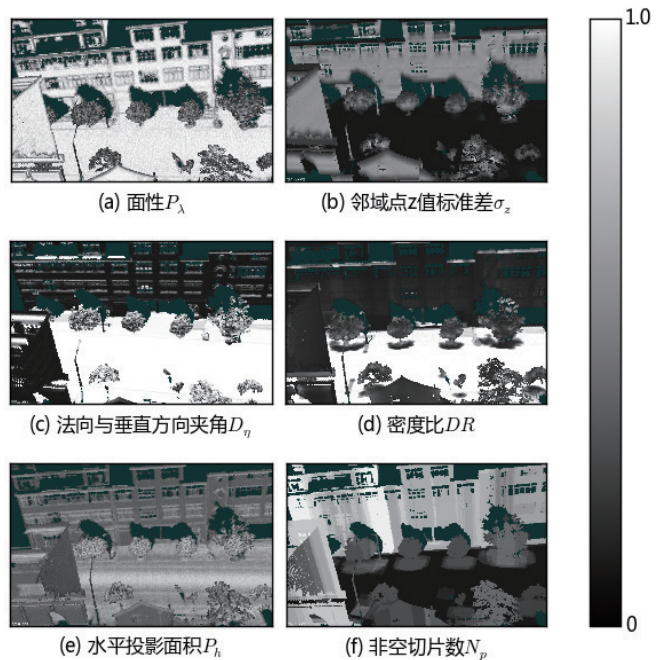


图2 点云特征 (图中显示值为归一化后特征值)
Fig.2 Point cloud feature(normalized value)

为了减少受邻域半径大小影响, 对于协方差相关特征、局部平面特征, 以及密度相关特征, 本文设定两个邻域半径, 以获取更多的邻域信息。最后对得到的特征向量进行归一化, 从而构建出20维的点云特征向量

$$X = \{L_\lambda, P_\lambda, S_\lambda, L'_\lambda, P'_\lambda, S'_\lambda, \Delta_z, \sigma_z, D_\eta, \sigma_\eta, D_p, D'_\eta, D'_p, DR, DR', P_h, P_v, L_{fph}, L_{vp}, N_p\}$$

2 基于Gradient Boosting的分类

本文采用Gradient Boosting方法^[11]作为分类器对已生成的点云特征向量进行训练及预测。Gradient Boosting方法结合了boosting^[12]与梯度下降的方法，从而获得最优的函数估计。Gradient Boosting的核心思想是不在参数空间估计最佳参数，而是在函数空间沿着梯度下降的方向进行最优化。

给定一个点云特征训练集 $\{x_i, l_i\}_i^N$ ，其中， x_i 为上述构建的点云特征向量， l_i 为点云的类别真值。我们需要估计分类函数 $F^*(x)$ 的最优估计 $\hat{F}(x)$ ，使得总体风险函数 $L(1, F(x))$ （对于点云分类问题，这里选择多类别的对数形式损失函数）最小：

$$F^* = \underset{F}{\operatorname{argmin}} E_{l,x} L(l, F(x)) = \underset{F}{\operatorname{argmin}} E_x [E_l(L(l, F(x))) | x] \quad (1)$$

通常将 $F(x)$ 视作一个参数化函数 $F(x; P)$ ， $P = \{P_1, P_2, \dots\}$ 是该函数的参数集。那么，组合若干个弱分类器，可以得到分类函数：

$$F(x; \{\beta_m, \alpha_m\}_m^M) = \sum_{m=1}^M \beta_m h(x; \alpha_m) \quad (2)$$

式中， $h(x; a)$ 是点云特征向量 x 的一个弱分类器，如决策树^[13]等。一般通过选择一个参数化模型 $F(x; P)$ ，将上述函数优化问题变为参数优化问题：

$$P^* = \underset{P}{\operatorname{argmin}} \Phi(P) \quad (3)$$

此处

$$\Phi(P) = E_{l,x} L(l, F(x; P))$$

因此可以得出：

$$F^*(x) = F(x; P^*)$$

使用数值优化方法来解决(3)式，则得到如下形式：

$$P^* = \sum_{m=0}^M p_m \quad (4)$$

这里 p_0 是估计的初始值，而 $\{p_m\}_m^M$ 是后续的增量，每一步都要基于前面的所有 p 值之和。使用梯度下降方法计算梯度如下：

$$g_m = \{g_{jm}\} = \left\{ \left[\frac{\partial \Phi(p)}{\partial p_j} \right]_{p=p_{m-1}} \right\} \quad (5)$$

由(4)式可知

$$p_{m-1} = \sum_{i=0}^{m-1} p_i \quad (6)$$

接下来计算

$$p_m = -\rho_m g_m \quad (7)$$

式中，

$$\rho_m = \arg \min_{\rho} \Phi(p_{m-1} - \rho g_m)$$

即 P 在梯度方向上下降的最佳距离。

Gradient Boosting方法将上述参数空间的梯度下降推广到函数空间，类似于参数模型的数值优化过程，有

$$F^*(x) = \sum_{m=0}^M f_m(x) \quad (8)$$

与(4)式类似，这里 $f_0(x)$ 是初始值， $\{p_m(x)\}_m^M$ 是增量函数。应用梯度下降，有：

$$f_m(x) = -\rho_m g_m(x) \quad (9)$$

式中，

$$g_m(x) = E_l \left[\frac{\partial L(l, F(x))}{\partial F(x)} | x \right]_{F(x)=F_{m-1}(x)}$$

类似地，这里

$$\rho_m = \arg \min_{\rho} E_{l,x} L(l, F_{m-1}(x) - \rho g_m(x))$$

对于点云特征向量集 $\{x_i, l_i\}$ ，由(2)式：

$$(\beta_m, a_m) = \arg \min_{\beta, a} \sum_{i=1}^N L(l_i, F_{m-1}(x_i) + \beta h(x_i; a))$$

由于对于每一个点 x_i ，都存在一个 $g_m(x_i)$ ，并且此梯度无法应用于其他点，因此，需要获取一个 $h(x; a_m)$ ，使得在所有点上 $h(x_i; a_m)$ 都最平行于 $g_m(x_i)$ ，根据最小二乘估计

$$a_m = \min_{a, \beta} \sum_{i=1}^N [-g_m(x_i) - \beta h(x_i; a)]^2 \quad (10)$$

然后计算沿梯度下降的距离：

$$\rho_m = \arg \min_{\rho} \sum_{i=1}^N L(l_i, F_{m-1}(x_i) + \rho h(x_i; a_m)) \quad (11)$$

最后得到分类函数：

$$F_m(x) = F_{m-1}(x) + \rho_m h(x; a_m) \quad (12)$$

由于点云分类是典型的多分类问题，假设所需分类的类别为 K ，则在 $\{1, 2, 3, \dots, M\}$ 次迭代中，每一次迭代都需要运行 K 个决策树，分别作为这 K 个类别的分类函数。

3 实验分析

本文以某城镇场景的车载点云数据为实验数据验证本文分类方法的有效性。数据的平均点密度为292/m²。试验环境为配备intel I7 2.3GHz处理器,16GB内存的计算机。由于源数据噪点较多,因此先进行预处理。实验选取了整个场景中部分具有代表性的区域点云共144W个点作为训练数据集。测试数据集为场景中另一较大区域的点云,共约312W点。本文将点云划分为9大类别:地面、建筑物、树木、路灯、电线杆、汽车、围墙、电力线,以及低矮灌木。由于场景中建筑物点与地面点较多,为了避免非均衡分类问题,从这3个场景中对所有类别抽取50 000个点用于训练,将剩下的点作为交叉验证数据集,用于调整模型参数,包括特征向量的构建参数,以及分类算法的参数。构建好分类器后,使用测试数据集对分类器进行测试。

3.1 分类结果分析

使用训练好的分类器对测试数据集进行分类,分类结果如图3所示。分类整体准确率为93.38%,混淆矩阵如图4所示。




图3 测试数据集(312W点)分类结果
Fig.3 Classification result of testing dataset (344W points)

从分类混淆矩阵可以看出,针对地面、建筑物、树、围墙、电力线,以及灌木都取得了较好的分类结果,而路灯、电线杆及汽车3类目标则存在一些误分类情况。对于路灯,由于存在许多被植被遮挡的情形,因此,大量路灯点被误分类为树。而对于电线杆,由于其本身与路灯的点特征极为相似,而逐点分类又难以提供完整的目标信息,因此,对于部分高度与路灯接近的电




图4 点云分类结果混淆矩阵
Fig.4 Confusion matrix of the point cloud classification result

线杆,则易被分类为路灯。此外,场景中的一些汽车由于遮挡以及其正在行驶等原因,其点云并不完整,因此被误分类为围墙、灌木等。这些误分类问题在基于逐点分类的结果进行目标提取时,通过区域生长组合等能够获取完整目标信息(如路灯的杆与其顶部灯的组合)的方法即可解决^[14]。

3.2 分类效率分析

对全部训练数据集构建特征向量耗时约24 h 18 min,其中,对点云特征直方图及垂直分布直方图的聚类占据绝大部分时间,约24 h左右。由于预测时无须重新聚类,因此,聚类耗时在预测时可被忽略。其余时间主要消耗在两个邻域中较大邻域相关的特征计算上,为了获取更多的邻域信息,本文使用了一大一小两个邻域。为了提高效率,可以适当减小邻域半径。使用已构建特征向量的样本点训练Gradient Boosting分类器,耗时约1 h 48 min。对测试数据集构建点云特征向量耗时约547 s,分类耗时约472 s。其中构建点云特征向量的时间仍然主要消耗在较大邻域的特征计算上。而分类由于逐点应用分类器即可,因此可采用并行计算,时间缩短为84 s,约为原来的1/5 - 1/6。

4 结束语

本文通过构建点云特征向量应用Gradient Boosting方法,完成了车载LiDAR点云的自动分类。实验表明本文的分类方法能够有效地对9类点云进行分

类,为后续基于机器学习的自动目标提取提供了较好的逐点分类结果。由于车载LiDAR点云场景复杂,数据量巨大,类别众多,以及存在大量遮挡情况,因此还需要进一步提高分类精度、改善分类效率。目前应用GPU计算的深度学习方法在图像识别和语音识别领域都取得了成功^[15],将GPU计算应用到涉及大量计算的点云特征向量构建过程^[16]中并引入深度学习方法,都会极大提升点云的自动分类效率。同时,加入更多表现局部环境上下文信息的特征,从而提升分类精度,也是需要进一步研究的问题。

参考文献

- [1] 杨必胜,魏征,李清泉,等.面向车载激光扫描点云快速分类的点云特征图像生成方法[J].测绘学报,2010,39(5):540-545.
- [2] 李婷,詹庆明,喻亮.基于地物特征提取的车载激光点云数据分类方法[J].国土资源遥感,2012,24(1):17-21.
- [3] 谭贲,钟若飞,李芹.车载激光扫描数据的地物分类方法[J].遥感学报,2012,16(1):50-66.
- [4] Boyko A S. Efficient interfaces for accurate annotation of 3D point clouds[D]. PRINCETON UNIVERSITY, 2015.
- [5] Serna A, Marcotegui B. Detection, segmentation and classification of 3D urban objects using mathematical morphology and supervised learning[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2014, 93: 243-255.
- [6] Puttonen E, Jaakkola A, Litkey P, et al. Tree classification with fused mobile laser scanning and hyperspectral data[J]. Sensors, 2011,11(5): 5158-5182.
- [7] Chehata N, Guo L, Mallet C. Airborne lidar feature selection for urban classification using random forests[J]. International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2009, 39(Part 3/W8): 207-212.
- [8] Rutzinger M, Höfle B, Pfeifer N. Detection of high urban vegetation with airborne laser scanning data[J]. Proceedings of ForestSat' 07, 2007.
- [9] Guo B, Huang X, Zhang F, et al. Classification of airborne laser scanning data using JointBoost[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015,100: 71-83.
- [10] Rusu R B, Blodow N, Beetz M. Fast point feature histograms (FPFH) for 3D registration[C]//Robotics and Automation, 2009. ICRA'09. IEEE International Conference on. IEEE, 2009:3212-3217.
- [11] Friedman J H. Greedy function approximation: a gradient boosting machine[J]. Annals of statistics, 2001:1189-1232.
- [12] Freund Y, Schapire R E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of computer and system sciences, 1997,55(1):119-139.
- [13] Breiman L, Friedman J, Stone C J, et al. Classification and regression trees[M]. CRC press, 1984.
- [14] Yang B, Dong Z. A shape-based segmentation method for mobile laser scanning point clouds[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2013, 81: 19-30.
- [15] Bengio Y. Learning deep architectures for AI[J]. Foundations and trends® in Machine Learning, 2009, 2(1): 1-127.
- [16] Liu M, Pomerleau F, Colas F, et al. Normal estimation for pointcloud using GPU based sparse tensor voting[C]//Robotics and Biomimetics (ROBIO), 2012 IEEE International Conference on. IEEE, 2012: 91-96.

本刊2014年入编北京市报刊发行局中国邮政主办的中邮阅读网(WWW.183read.com)。该著作权使用费将与本刊稿酬一次性给付,不再另行发放。作者如不同意入编,投稿时敬请说明,本刊另作处理。