

一种融合多特征聚类集成的室内点云分割方法

曾 碧 黄 文

(广东工业大学 计算机学院 广州 510006)

摘 要: 针对特定场景下传统点云分割算法不精确及特征描述不全面的问题,提出一种融合2D和3D多特征的近邻传播(AP)聚类集成分割方法。从点云中获​​得一组表征复杂室内场景不同点云类别的描述子,如彩色图像特征、曲率、法向量、旋转图像等,根据它们之间的差异性,通过对每类特征进行AP聚类得到聚类成员,建立聚类成员簇间一致性矩阵,并利用Ncut算法进行图分割获得最终的点云分割结果。实验结果表明,该算法相较于传统的点云分割算法能更准确地区分室内复杂三维点云场景,并且具有更好的稳定性。

关键词: 点云分割; 特征融合; 近邻传播聚类算法; 聚类成员; 聚类集成

中文引用格式: 曾 碧 黄 文. 一种融合多特征聚类集成的室内点云分割方法[J]. 计算机工程 2018, 44(3): 281-286.

英文引用格式: ZENG Bi, HUANG Wen. An Indoor Point Cloud Segmentation Method Fusing with Multi-feature Cluster Ensemble[J]. Computer Engineering 2018, 44(3): 281-286.

An Indoor Point Cloud Segmentation Method Fusing with Multi-feature Cluster Ensemble

ZENG Bi, HUANG Wen

(School of Computers, Guangdong University of Technology, Guangzhou 510006, China)

【Abstract】 Aiming at the problem that the traditional point cloud segmentation algorithm is not precise and feature description is not comprehensive in specific scenes, an Affinity Propagation (AP) clustering ensemble segmentation method fusing with 2D and 3D features is proposed. Firstly, a set of descriptors representing different cloud types of complex indoor scenes, such as colour image features, curvature, normal vectors, rotating images are obtained from point clouds. Secondly, according to the difference between them, the clustering members are obtained by AP clustering for each class of features, and the cluster consensus matrix is established. Finally, the final segmentation result is obtained by using Ncut algorithm. Experimental results show that the proposed method is better than traditional point cloud segmentation algorithm in distinguishing indoor 3D point cloud scene, and has better stability.

【Key words】 point cloud segmentation; feature fusion; Affinity Propagation (AP) clustering algorithm; clustering member; clustering ensemble

DOI: 10.3969/j.issn.1000-3428.2018.03.047

0 概述

复杂三维室内场景的点云分割是指移动机器人获取场景中的特征信息后,根据这些特征信息识别出不同的物体。室内复杂场景的自动点云分割是机器视觉、人工智能等领域的热门研究课题,是移动机器人实现自主场景理解和任务规划的重要基础。

现有的点云分割方法主要划分为3类:基于聚类的分割方法^[1-2],基于特征线的分割方法^[3]和基于区域增长的分割方法^[4]。基于特征线的分割方法通过搜索特征点,将特征点连接形成特征线,其分割效果在很大程度上取决于特征边缘探测器;基于区域

增长的分割算法从选定的种子点开始,逐步扫描周围的数据点并判断该点是否满足特定的规则,合乎规则的点被纳入到同一区域中。基于聚类的分割方法采用机器学习的分析方法,每个点都与一个特征向量相关联,根据点云数据特征识别聚类模式,然后将具有相同模式的点云数据分割在一起。

由于室内物体多样化,而且存在互相遮挡、边缘特征不显著、低层视觉特征辨识能力弱等特点,在这种场景下基于边缘检测的分割算法不易确定边界、基于区域增长分割算法的效果取决于种子点的选择,算法分割效果不稳定^[5]。基于聚类的分割方法目前通常只利用了点云数据的某一类特征,在室内复杂场景下,聚类分割

基金项目: 广东省产学研合作专项(2014B090904080); 广东省科技发展重大专项(2016B010108004); 广州市重点科技项目(201604020016)。

作者简介: 曾 碧(1963—),女,教授,主研方向为智能机器人、人工智能、移动计算; 黄 文,硕士。

收稿日期: 2017-02-13 修回日期: 2017-03-16 E-mail: 15602386232@163.com

方法容易出现分割不足或分割过度的情况。针对以上问题,考虑到聚类集成和单聚类算法相比可得到一种能较好反映数据集内在结构的数据划分,结合点云包含环境的颜色、纹理及三维几何信息,本文提出一种融合多特征的近邻传播(Affinity Propagation, AP)聚类集成分割方法。

1 相关研究

1.1 特征构造

点云数据是对室内场景进行扫描采样获得的离散数据,由于曲率是曲面的重要局部几何属性,所以曲率能够用于三维点云特征点的分析与识别。文献[6]在三维点云曲率方面提出多种方法。文献[7]总结国内外有关点云数据的研究现状,提出一种基于空间分割和曲率特征信息的点云数据精简算法。文献[8]通过扩展数学形态方法与构造符号距离函数估算点云的平均曲率,并运用中值滤波方法去除点云噪声对曲率估算精度的影响,进而在保证点云分割精度的同时有效提高了计算效率。

除曲率这一几何特性外,有研究表明,点云数据的法向量能更好地表示局部领域内的方向特性。如文献[9]在研究点云处理中容易丢失曲面细节特征的问题时,提出一种尖锐特征曲面散乱点云法向估计法,该方法首先用主成分分析法粗略估计点云法向量,然后根据邻域点的距离加权更新当前的法向量,由此在点云处理时保留曲面的尖锐特征,最终获得对噪声比较好的鲁棒性。文献[10]针对散乱点云简化中易丢失几何特征及潜在曲面形状信息的问题,提出保留几何特征的散乱点云简化算法。可以得知曲率相比颜色特征更能表示点云局部领域内的凹凸或边缘特性。

此外,旋转图像描述子在三维空间具有更好的旋转不变性、尺度不变性等优点。文献[11]在传统算法的基础上针对不同的三维场景,充分利用旋转图像描述子在三维空间更好的旋转不变特性,提出改进算法,改进的算法在匹配精度和运行时间上改善比较明显。受此启发,针对室内堆放杂乱无序的复杂场景,本文在原始点云的基础上,对点云中的点进行扩展,构造融合原始采集像素坐标信息、深度信息、曲率特征信息、法向量特征信息、旋转图像特征的多维融合特征。

1.2 点云聚类分割算法

在点云聚类方法中,每个样本点都与一个特征向量相关联,特征向量又包含了若干几何度量值。通过聚类的方法,如K-means法、最大似然法和模糊聚类法,可分割点云数据。聚类方法的性能取决于特征之间的相似性和聚类方法的选择。文献[12]提出一种基于谱聚类的分割算法,该方法基于视觉理论的最小值原则构造点云模型的相似矩阵,使用归一化的非对称Laplacian矩阵将输入的点云模型映射到谱空间,最后使用K-means聚类对点云模型进

行分割。文献[13]针对林下环境几何特征的复杂性,提出一种基于特征融合的聚类分割方法,该方法能较好地保留数据特征。

聚类集成通过对原始数据集的多个聚类结果进行学习 and 集成,能够得到一种较好反映数据集内在结构的数据划分。文献[14]针对现有单聚类效果不好、传统集成方法在处理模糊聚类时存在的不足,提出一种基于证据理论的模糊聚类集成方法,实验结果表明该方法具有较高的聚类性能。文献[15]系统综述了聚类集成的相关研究进展和未来的研究方向。综上所述,聚类集成利用集成学习方法,通过学习合并数据集的多个聚类结果而得到一个新的聚类方案,可使聚类效果更加鲁棒。

考虑到存在堆积或混杂凌乱的复杂场景下的点云分割中单维度特征空间聚类方法的分割效果不好,如颜色特征相同、距离不同的三维点簇可能被错误分割,所以,考虑采用多维空间的特征描述子,并结合集成聚类鲁棒性强、能从不同的视角探索点云数据内在结构这一特点,本文尝试将AP聚类集成运用在复杂室内场景的点云分割中。

2 融合多特征的 AP 聚类集成方法

2.1 点云特征生成

点云的法向量是点在空间分布的重要特征,所以,估算点云的法向量是点云分割过程中的一个重要部分。考虑到室内场景点云数据的空间结构,本文将某一点(p 点)邻域内的 k 个近邻点拟合成一个曲面,并将曲面中该点处的法向量作为估算值。点云法向量示意图如图1所示。




图1 点云法向量示意图

为了获得点云中某一点的曲率,首先计算该点的 k 个邻近点,构建三角网格,然后沿着 z 轴方向计算每个三角网格的法向量,最后对估计点的邻近三角网格的法向量进行加权求取结果。其计算过程如式(1)所示。

$$N_p = \frac{\sum_{i=1}^k n_i}{k} \quad (1)$$

其中 N_p 表示点云 p 的估计法向量; n_i 表示邻近三角网格 i 的法向量; k 表示该 p 点临近点的数目。

曲率信息反映三维曲面的又一重要特征,在点云曲面的建模、分割过程中起着非常重要的作用。在点云的数据处理中尤其以平均曲率和高斯曲率的

应用最为广泛。文献[16]提出采用基于MLS面(Moving Least Squares Surfaces)方法计算曲率,这种计算方式的优点是可以在一定噪声水平下快速有效地计算出点云中每一点的高斯曲率、平均曲率和主曲率。本文中,采用类似的方法计算曲率,其中MLS面的定义过程如下:MLS面是能量函数 $e(y, a)$ 沿着向量场 $n(x)$ 方向的局部最小值。其中 $n(x)$ 和 $e(y, a)$ 计算公式如式(2)所示。

$$n(x) = \frac{\sum_{q_i \in Q} v_i \theta(x, q_i)}{\left\| \sum_{q_i \in Q} v_i \theta(x, q_i) \right\|} \quad (2)$$

$$k_{\text{Gaussian}} = \frac{\text{Det} \begin{pmatrix} H(g(x)) & \nabla^T g(x) \\ \nabla g(x) & 0 \end{pmatrix}}{\left\| \nabla g(x) \right\|^4} \quad (5)$$

$$k_{\text{Mean}} = \frac{\text{Det} \left\| \nabla g(x) \right\|^3 \cdot \text{Trace}(H) - \nabla g(x) \cdot H(g(x)) \cdot \nabla^T g(x)}{\left\| \nabla g(x) \right\|^3} \quad (6)$$

由高斯曲率和平均曲率可以得到主曲率:

$$k_{\pm} = k_{\text{Mean}} \pm \sqrt{k_{\text{Mean}}^2 - k_{\text{Gaussian}}} \quad (7)$$

旋转图像是一种三维物体描述的全局配准技术,为了更好地描述一定区域内的曲面形状,可以将三维曲面分割成有限元网络,在每个节点上都计算出一个旋转图像。随着选取的节点数目的增多,可以借助旋转图像逐步由局部特征演变成全局特征,进而可以描述一定区域内的曲面形状。给定一个三维曲面 Q , p 是曲面 Q 上的某一有向点, n 为 p 点所对应的法线。 P 是垂直于法线 n 且过 p 点的切平面,直线 L 经过 p 点并平行于法线 n 。其他 x 点旋转映射坐标为 (α, β) ,其中 α 为 p 和 x 两点处法向量 n 之间的距离, β 为点 x 与切平面的有向距离,如图2所示。




图2 旋转图像示意图

三维数据投影到由 (p, n) 确定的二维坐标系下的映射函数 $S_o(x)$ 表达式如式(8)和式(9)所示,选定有向点 p 以后,三维曲面上的任意一点 x 与 p 的关系通过 (α, β) 来表达,旋转图像就是该有向点邻域的 (α, β) 坐标的二维图像。

$$S_o(x) : \mathbb{R}^3 \rightarrow \mathbb{R}^2 \quad (8)$$

$$S_o(x) \rightarrow (\alpha, \beta) = \left\{ \sqrt{\|x-p\|^2 - (n \cdot (x-p))^2}, n \cdot (x-p) \right\} \quad (9)$$

2.2 AP聚类成员生成

曲率能表现局部区域的平滑性,法向量能表现

$$e(y, a) = \sum_{q_i \in Q} ((y - q_i) \cdot a)^T \theta(x, q_i) \quad (3)$$

其中 y, a 分别是位置向量和方向向量, q_i 是输入点云中的点, v_i 为 q_i 对应的法向量, $\theta(x, q_i)$ 表示高斯加权函数。

在式(2)、式(3)的基础上,对函数 $e(y, a)$ 求偏导数,可以求得极小值点。

$$g(x) = n(x)^T \frac{\partial e(y, n(x))}{\partial y} \Big|_{y=x} \quad (4)$$

由式(4)可得MLS面表达式,则高斯曲率和平均曲率如式(5)和式(6)所示。

邻近平面区域的方向性等特征,这些特征是三维点云之间聚类的重要依据。在2.1节中针对点云的每一点利用三维几何特性进行特征扩充,但是由于不同的特征对于衡量点与点的距离具有不同的标准,难以用统一的度量标准来衡量点与点之间的距离。此外,文献[17-18]指出不同组的特征互不关联,从每个分组中随机选择一个特征生成特征子集,便可得到多个既存在差异性又具备区分能力的特征子集,然后分别在对应的特征子空间进行聚类运算,最后采用Ncut进行集成融合。受此启发,本文依据点云中不同的几何属性构造划分子集的聚类集成框架,如图3所示。

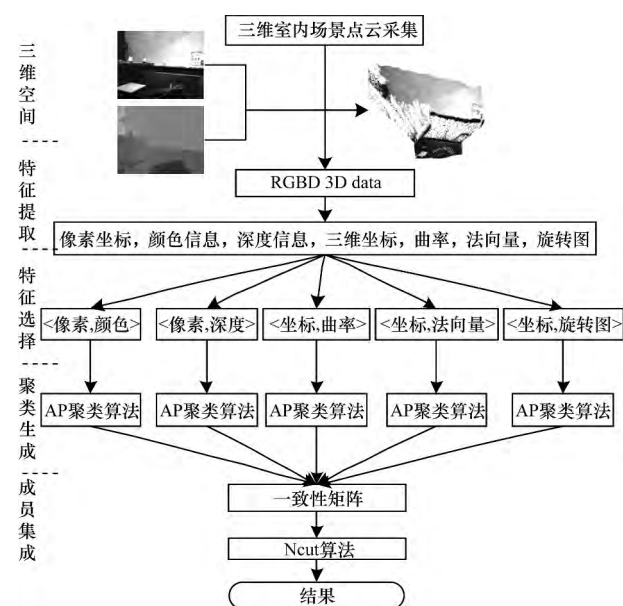


图3 聚类集成框架

文献[19]提出的AP聚类算法以其良好的特性成为近年来的研究热点,AP算法首先构造相似度矩阵描述样本数据点之间的相似度,然后借助相似度矩阵实现

一种包含可信度信息 R (Responsibility) 和可用度信息 A (Availability) 的消息传递机制,借助这两种信息交替更新迭代,最终通过决策矩阵 E 得到聚类中心集合。假设有 n 个数据,这些数据点构成一个 $n^* n$ 的相似度矩阵 S , $S(i, j)$ 表示数据点 i 与 j 之间的相似度,可以使用式(10)进行计算。

$$S(i, j) = -\|x_i - x_j\|^2, S(i, j) \in (-\infty, 0] \quad (10)$$

聚类中心的评判由相似度矩阵对角线上的元素值决定, $S(i, i)$ 称为偏向参数,是 AP 算法中的一个重要参数,表示数据点 i 作为类代表点的适合程度,其值越大表示该数据点越适合作为聚类中心。可信度 $r(i, k)$ 表示点 x_k 适合做点 x_i 类代表点的可信程度,可用度 $a(i, k)$ 则表示点 x_k 选择点 x_i 做类代表点的适合程度,迭代公式如下所示:

$$r(i, k) = S(i, k) - \max\{a(i, k) + S(i, k)\} \quad (11)$$

$$a(i, k) = \begin{cases} \min_{j \neq k} \{0, r(k, j) + \sum \max\{0, r(j, k)\}\} & i \neq k \\ \sum_{j \neq i} \max\{0, r(j, k)\} & i = k \end{cases} \quad (12)$$

算法在迭代过程中引入阻尼因子来提高其稳定性,确保每一次迭代的 $r(i, k)$ 和 $a(i, k)$ 的值受上一次迭代值的约束,如下式所示:

$$r(t) = (1 - \lambda) r(t) + \lambda r(t - 1) \quad (13)$$

$$a(t) = (1 - \lambda) a(t) + \lambda a(t - 1) \quad (14)$$

AP 算法通过持续迭代更新每一个点的可信度和可用度,直至限定的迭代次数或趋于收敛,最终形成类簇。

2.3 聚类集成

构造聚类成员后,聚类集成的关键问题是如何根据这些由聚类成员得到的簇标签构造数据点之间的相似度矩阵。具体来说,给定一个室内场景具有 k 维特征的 n 个点云数据集 $P = \{p_1, p_2, \dots, p_n\}$,对每一个特征进行模糊 AP 聚类,得到一类聚类成员 $\{I_1, I_2, \dots, I_n\}$,然后对聚类成员 $I^b (b \in \{1, 2, \dots, k\})$ 构造一个邻接矩阵 A^b ,邻接矩阵 A^b 中的元素 $a_{ij}^b (i, j \in \{1, 2, \dots, n\})$ 定义如下:

$$a_{ij}^b = \begin{cases} 1 & \mu_i = a_j \\ 0 & \mu_i \neq a_j \end{cases} \quad (15)$$

其中 μ_i 和 a_j 分别代表 2 个点云数据 p_i 和 p_j 聚类点云的簇标签。

通过上述每个邻接矩阵可以得到一致性矩阵 W ,其计算公式如下:

$$W = \frac{1}{k} \sum_{i=0}^k A^i \quad (16)$$

在获得一致性矩阵后,采用文献[20]提出的 Ncut 对其进行分割,获得最终的点云分割结果。首先,构建一个图 $G = (P, W)$,其顶点 P 集合代表三维

点云中点的集合,图 G 的边用一致性矩阵 W 中的元素 W_{ij} 表示。然后,用 Ncut 算法把点云数据集 P 递归的分割成 P_1^*, P_2^* 2 个子集,直至获得三维点云场景中物体数目 k 。目标函数 $\nabla(P_1^*, P_2^*)$ 旨在最小化点聚类簇之间的距离,以此获得最大化点云簇内的相关性,公式如下:

$$\nabla(P_1^*, P_2^*) = \frac{\alpha(P_1^*, P_2^*)}{\beta(P_1^*, P)} + \frac{\alpha(P_1^*, P_2^*)}{\beta(P_2^*, P)} \quad (17)$$

$$\alpha(P_1^*, P_2^*) = \sum_{p_i \in P_1^*, p_j \in P_2^*} W_{ij} \quad (18)$$

$$\beta(P_k^*, P) = \sum_{p_i \in P_1^*, p_j \in P} W_{ij}, k = 1, 2 \quad (19)$$

其中, $\nabla(P_1^*, P_2^*)$ 表示 P_1^* 和 P_2^* 点云簇之间的分离度量, W_{ij} 是一致性矩阵 W 中的元素,代表点云中每个点之间的相似性权重。

为了方便求解,可简化目标函数 $\nabla(P_1^*, P_2^*)$ 如下:

$$\nabla(P_1^*, P_2^*) = \frac{\sum_{\substack{j=n \\ p_i > 0, p_j < 0}} -W_{ij} p_i p_j}{\sum_{\substack{j=0 \\ p_i > 0, p_j = 0}} W_{ij}} + \frac{\sum_{\substack{j=n \\ p_i < 0, p_j > 0}} -W_{ij} p_i p_j}{\sum_{\substack{j=0 \\ p_i < 0, p_j = 0}} W_{ij}} \quad (20)$$

其中 $p_i (i \in \{1, 2, \dots, n\})$ 取值是 $\{-1, 1\}$, $p_i = 1$ 表示点云 i 属于 P_1^* 点云簇; $p_i = -1$ 表示点云 i 属于 P_2^* 点云簇。

基于目标函数 $\nabla(P_1^*, P_2^*)$ 等价于 $\nabla(P)$ 最小化问题,公式如下:

$$\min_P \nabla(P) = \min_{\delta} \frac{\delta(U - W)\delta}{\delta^T U \delta} \quad (21)$$

$$\delta = (1 + P) - \mu(1 - P) \quad (22)$$

$$\mu = \frac{\sum_{p_i > 0} \delta_i}{\sum_{p_i < 0} \delta_i} \quad (23)$$

约束条件为 $\delta_i \in (-\tau, 1]$, $\delta^T U I = 0$ 。其中 $P = [p_1, p_2, \dots, p_n]^T$ 表示 n 个点云数据; $\delta = \sum_{j=0}^n W_{ij}$ 表示 $n \times n$ 对角矩阵 U ; I 代表单位矩阵; δ_i 是矩阵 δ 中的元素。

3 实验结果与分析

为了验证本文所提出的算法在点云数据集上的分割性能,选用 NYU2 数据集^[21]进行实验,该数据集包括 1 449 个不同室内场景的环境,包括办公室、走廊、房间等,且该数据集已提供人工标准的分割结果。在原始 NYU2 数据集的基础上,通过预处理的方式获得三维点云数据,进而生成点云的相关特征。

3.1 直观评价

为了从直观感觉上对比不同算法的分割性能,本文在相同实验数据集下,分别采用 K-means 聚类算法、AP 聚类算法、FCM 算法(Fuzzy C-Means algorithm)以及本文提出的算法获得点云分割效果直观图,如图 4 所示。



图4 不同算法分割实验结果对比

图4(a)和图4(b)分别为原始二维颜色图和深度图,图4(c)为三维空间的点云图。K-means算法、AP算法和FCM算法的分割结果分别如图4(e)、图4(f)和图4(g)所示。本文算法的分割结果如图4(h)所示。从左至右的场景分别为客厅、书房、厨房和卧室。从上述实验直观结果可以看出,本文算法与K-means算法、AP算法、FCM算法相比具有较好的分割效果。这是因为室内场景结构较复杂,传统的聚类分割方法分割不精确,且特征描述不全面。本文提出的算法是在融合点云特征的基础上采用基于AP算法的集成聚类分割方法,这种方法通过对点云数据构造一系列特征,能够更有效地表征复杂场景下不同点云的类别。

3.2 客观评价

为了客观地比较融合不同特征的算法分割结果,本文采用正确分割率(CCR)度量准则来评价各算法的分割结果,CCR定义如下:

$$CCR = \sum_{i=1}^k \frac{|Y_i \cap T_i|}{G} \quad (24)$$

其中 Y_i 表示标准分割结果属于 i 类的三维点, T_i 表示算法分割结果属于 i 类的三维点, $Y_i \cap T_i$ 表示 i 被正确分割的三维点数, G 代表点云总个数。 $CCR \in [0, 1]$,CCR越大表明分割越好。

表1中显示了不同场景下本文算法融合不同特征进行集成聚类的正确分割率,特征包括颜色信息、深度信息、法向量信息、曲率信息、旋转图信息及其组合特征。

表1 不同场景下本文算法的正确分割率

相关特征 AP 聚类	场景 1	场景 2	场景 3	场景 4
颜色	0.552	0.492	0.416	0.431
深度	0.605	0.582	0.543	0.610
法向量	0.405	0.368	0.461	0.484
颜色 + 深度 + 曲率 + 法向量 + 旋转图	0.792	0.821	0.807	0.810

通过分析表1数据可以看出,与单特征AP聚类算法相比,融合多信息集成聚类的算法能更好地分割三维点云的复杂场景。通过融合二维空间的颜色、深度和三维空间的曲率、法向量、旋转图等特征,能更好地弥补单一特征难以区分复杂的局部纹理特征的局限性。这是因为在度量不同点云数据点的相似性时,本文算法充分考虑了三维点云曲率、点云法向量以及旋转图像描述子等多维特征,使得聚类的内聚性得到增强,集成聚类效果更加稳定且效果更优。

4 结束语

本文针对结构复杂的室内场景下传统的点云分割算法不精确、单聚类算法分割效果较差的问题,提出一种融合点云多特征的集成聚类分割方法,该方法充分考虑三维点云曲率、法向量以及旋转描述子等多特征融合的聚类集成。实验结果表明,在融合多特征条件下,该算法相比传统的单聚类算法能够更好地区分具有三维复杂场景的点云数据。后续工作将在原有多特征融合的基础上继续研究和改进,在结合新特征的同时解决单一特征难以描述分割的问题。

参考文献

- [1] YAN X W, FENG L, LIU F, et al. Point Cloud Segmentation Using Euclidean Cluster Extraction Algorithm with the Smoothness [J]. Measurement and Control Technology, 2016, 35(3): 36-38.
- [2] LIU X, NING X, XIA S. A Method for Powerline LiDAR Point Cloud Segmentation Using K-means Clustering of a Feature Space [J]. Science of Surveying and Mapping, 2016, 215(5): 60-63.

- [3] 张大鹏,郑德华,夏佳毅. 基于特征线的点云数据分割算法[J]. 地理空间信息 2015(3): 120-121.
- [4] 杨飞,周凡,王若梅,等. 一种快速有效的基于区域增长的网格分割算法[C]//全国几何设计与计算学术会议. 大连: 中国工业与应用数学学会几何设计与计算专业委员会 2013: 207-211.
- [5] KIM S J, LEE I P. Simulation Based Performance Assessment of a LIDAR Data Segmentation Algorithm [J]. Journal of Korean Society for Geospatial Information System 2010, 18(2): 119-129.
- [6] CZERNIAWSKI T, NAHANGI M, HAAS C, et al. Pipe Spool Recognition in Cluttered Point Clouds Using a Curvature-based Shape Descriptor [J]. Automation in Construction, 2016, 71(8): 346-358.
- [7] 葛源坤,黎荣,李海伦. 空间分割与曲率相融合的点云精简算法研究[J]. 计算机应用研究 2012, 29(5): 1997-2000.
- [8] 莫堃,尹周平. 基于 3D 活动轮廓模型的缺陷点云分割方法[J]. 华中科技大学学报(自然科学版) 2011, 39(1): 82-85.
- [9] 袁小翠,吴禄慎,陈华伟. 尖锐特征曲面散乱点云法向估计[J]. 光学精密工程 2016, 34(10): 2581-2588.
- [10] 张雨禾,耿国华,魏潇然,等. 保留几何特征的散乱点云简化算法[J]. 计算机辅助设计与图形学学报 2016, 28(9): 1420-1427.
- [11] HE Y, MEI Y. An Efficient Registration Algorithm Based on Spin Image for LiDAR 3D Point Cloud Models [J]. Neurocomputing 2015, 151(1): 354-363.
- [12] 马腾,龙翔,冯路,等. 点云模型的谱聚类分割[J]. 计算机辅助设计与图形学学报 2012, 24(12): 1549-1558.
- [13] 樊丽,刘晋浩,黄青青. 基于特征融合的林下环境点云分割[J]. 北京林业大学学报 2016, 38(5): 133-138.
- [14] 毕凯,王晓丹,邢雅琼. 基于模糊测度和证据理论的模糊聚类集成方法[J]. 控制与决策 2015, 30(5): 823-830.
- [15] TENG G, HE C, XIAO J, et al. Cluster Ensemble Framework Based on the Group Method of Data Handling [J]. Applied Soft Computing 2016, 43(C): 35-46.
- [16] 马忠玲,周明全,耿国华,等. 一种基于曲率的点云自动配准算法[J]. 计算机应用研究 2015, 32(6): 1878-1880.
- [17] AMIRI N, YAO W, HEURICH M, et al. Estimation of Regeneration Coverage in a Temperate Forest by 3D Segmentation Using Airborne Laser Scanning Data [J]. International Journal of Applied Earth Observation and Geoinformation 2016, 52(6): 252-262.
- [18] 王连喜,蒋盛益. 一种基于特征聚类的特征选择方法[J]. 计算机应用研究 2015, 32(5): 1305-1308.
- [19] FREY B J, DUECK D. Clustering by Passing Messages Between Data Points [J]. Science 2007, 315(5814): 972-976.
- [20] SHI J, MALIK J. Normalized Cuts and Image Segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence 2000, 22(8): 888-905.
- [21] SILBERMAN N, HOIEM D, KOHLI P, et al. Indoor Segmentation and Support Inference from RGBD Images [C]// Proceedings of European Conference on Computer Vision. Berlin, Germany: Springer 2012: 746-760.

编辑 吴云芳

(上接第 280 页)

- [5] CIMARUSTI D L, SAITO K, VAUGHN J E, et al. Extraction of Ridge and Valley Lines from Unorganized Points [J]. Multimedia Tools and Applications 2013, 63(1): 265-279.
- [6] WEBER C, HAHMANN S, HAGEN H, et al. Sharp Feature Preserving MLS Surface Reconstruction Based on Local Feature Line Approximations [J]. Graphical Models 2012, 74(6): 335-345.
- [7] MERIGOT Q, OVSJANIKOV M, GUIBAS L J. Voronoi-based Curvature and Feature Estimation from Point Clouds [J]. IEEE Transactions on Visualization and Computer Graphics 2011, 17(6): 743-756.
- [8] GUMHOLD S. Feature Extraction from Point Clouds [C]// Proceedings of IMR'01. Newport Beach, USA: [s. n.], 2001: 293-305.
- [9] PAULY M, KEISER R, GROSS M. Multi-scale Feature Extraction on Point-sampled Surfaces [J]. Computer Graphics Forum 2003, 22(3): 281-289.
- [10] NIE J. Extracting Feature Lines from Point Clouds Based on Smooth Shrink and Iterative Thinning [J]. Graphical Models 2016, 84(C): 38-49.
- [11] 聂建辉,刘焯,高浩,等. 基于符号曲面变化度与特征分区的点云特征线提取算法[J]. 计算机辅助设计与图形学学报 2015, 27(12): 2332-2339.
- [12] DANIELS J I, HA L K, OCHOTTA T, et al. Robust Smooth Feature Extraction from Point Clouds [C]// Proceedings of IEEE International Conference on Shape Modeling and Applications. Washington D. C., USA: IEEE Press 2007: 123-136.
- [13] 庞旭芳,庞明勇,肖春霞. 点云模型谷脊特征的提取与增强算法[J]. 自动化学报 2010, 36(8): 1073-1083.
- [14] ALEXA M, BEHR J, COHEN-OR D, et al. Computing and Rendering Point Set Surfaces [J]. IEEE Transactions on Visualization and Computer Graphics 2003, 9(1): 3-15.
- [15] ZHANG Y, GENG G, WEI X, et al. A Statistical Approach for Extraction of Feature Lines from Point Clouds [J]. Computers and Graphics 2016, 56(C): 31-45.
- [16] DEY T K, GE X, QUE Q, et al. Feature-preserving Reconstruction of Singular Surfaces [J]. Computer Graphics Forum 2012, 31(5): 1787-1796.
- [17] MIN K P, LEE S J, LEE K H. Multi-scale Tensor Voting for Feature Extraction from Unstructured Point Clouds [J]. Graphical Models 2012, 74(4): 197-208.

编辑 金胡考